

Machine Learning - Python

ANÁLISIS CALIDAD AGUA



Kaled


Resumen

Este informe detalla el estudio realizado sobre una base de datos de 3,276 muestras de agua. El objetivo principal fue identificar si los parámetros químicos estándar permiten predecir con exactitud si el agua es apta para el consumo humano (Potabilidad).

Hallazgos principales

Matriz de Correlación: ¿Están relacionadas las variables?

GRÁFICO 1: Tabla de correlación



Al analizar cómo se afectan las variables entre sí, los resultados muestran que no existe una dependencia lineal clara.

Los valores cercanos a 0 indican que factores como el pH o la dureza se comportan de forma independiente. No porque el pH suba, la dureza subirá necesariamente.

Es el hallazgo más crítico. Ninguna medición por sí sola (pH, sulfatos, etc.) tiene una correlación fuerte con la potabilidad. Esto significa que ser potable no depende de un solo ingrediente químico, sino de una receta compleja de todos ellos.

Análisis Visual: pH vs. Dureza y Cloraminas

A través de los gráficos de dispersión (scatter plots), observamos lo siguiente:

El fenómeno del "Solapamiento": En los gráficos, los puntos de agua potable (naranja) y no potable (azul) están totalmente mezclados.

Conclusión: Un agua con pH "perfecto" (7.0) y niveles de cloraminas o dureza dentro de la norma puede seguir siendo no potable. El gráfico confirma que la seguridad del agua es un problema multivariante que no se resuelve con reglas simples.

Gráfico 2: pH vs Dureza





Gráfico 3: pH vs Cloraminas



Inteligencia Artificial y Predicción

Dado que la estadística tradicional y los gráficos simples no logran separar el agua buena de la mala, se recurre a algoritmos de Machine Learning. Estos programas son capaces de encontrar patrones ocultos donde el ojo humano solo ve una "nube" de puntos.

Los modelos de "ensamble" (que combinan múltiples decisiones pequeñas para dar un veredicto final) fueron los más exitosos:

Gráfico 4: Tabla de resultados

Modelo de IA	Eficacia (% Aciertos)	Interpretación
Random Forest	89%	El más robusto; ideal para datos complejos.
Bagging	89%	Excelente estabilidad en las predicciones.
KNN	85%	Clasifica basándose en "vecinos" o muestras similares.
XGBoost	80%	Rápido, aunque en este caso fue menos preciso.

Conclusión

El análisis demuestra que la potabilidad del agua no puede determinarse mirando un solo parámetro. Sin embargo, gracias al uso de Inteligencia Artificial (especialmente Random Forest), podemos predecir con un 89% de certeza si el agua es segura para el consumo analizando todas las variables en conjunto.

Esto sugiere que, en el futuro, los sensores inteligentes podrían usar estos modelos para alertar sobre la calidad del agua en tiempo real.